LocalPass 외국인 관광객을 위한 로컬 후기 신뢰도 필터링 서비스

팀	류황규 · 박건우 · 홍승우 · 황지룡	**지원 분야**	AI·DX 산출물
서비스 주소	https://localpass-kappa.vercel.app	**제출물**	코드 설명서, 코드 결과(PPT 20 장), 소스 코드

1. 개발 배경과 목적

- 외국인이 주로 쓰는 구글맵은 한국 데이터가 부실하고, 가장 믿을 만한 **네이버 블로그 후기는 한국어로만 유통**됩니다. 번역해도 **숨은 광고와 AI 가 쓴 글은 가려낼 수 없고**, 광고 수익 구조상 콘텐츠가 유명 장소에 쏠려 **지방은 정보 사각지대**로 남습니다.
- LocalPass 는 공공 관광데이터(TourAPI)와 블로그 후기를 결합하고 **숨은 광고·AI 작성 글은 걸러내고 협찬을 밝힌 글은 '협찬 고지'로 표시해** 진짜 사람의 후기를 4 개 언어로 보여줍니다. 조사한 경쟁 서비스 6 곳(크리에이트립, 망고플레이트, 와그, 트래지, 캐치테이블, 네이버지도)에는 이런 검증 기능이 없습니다.

2. 주요 기능

구분	내용
장소 탐색	지역 6 곳(성수·전주·부산·강릉·경주·제주)과 전국 키워드 검색, 카테고리 탭(관광지·문화시설·축제·전통시장·맛집), 관심사 9 종 필터, 신뢰도순·거리순·이름순 정렬
장소 상세	TourAPI 공식 정보(주소·이용시간·쉬는 날·요금·소개)를 관광공사 공식 외국어 번역으로 우선 표시하고, 없으면 Qwen 번역에 '기계 번역' 표시
후기 신뢰도 분석	장소별 네이버 블로그 후기 6 건을 7 단계로 검사해 도장 배지(신뢰·참고·협찬 고지·의심·차단), 신뢰도 점수, 판단 근거, 번역 요약을 끝나는 대로 한 건씩 표시 (진행 건수·경과 시간 표시)
의심 후기 처리	숨은 광고·AI 의심·차단 글은 숨기되 지우지 않고 펼치면 근거 공개. 협찬을 밝힌 글은 '협찬 고지'로 표시
직접 후기 검사	후기를 붙여 넣으면 같은 7 단계로 검사 (샘플: 진짜 후기 · 협찬 글 · 프롬프트 인젝션)
다국어 · 모바일	화면 문구·후기 요약·장소명 4 개 언어, 주소는 영문 표기와 한국어 원래 주소 병기(택시·지도용), 스마트폰(390px) 대응, 키보드 초점·'움직임 줄이기' 설정 지원
GPU 온디맨드	AI 서버는 사이트를 쓸 때만 켜지고 5 분간 쓰지 않으면 꺼짐. 켜지는 동안(2~4 분) 화면 하단에 경과 시간 안내

3. 시스템 구성과 기술 스택

외국인 관광객
브라우저 · 모바일
영·일·중·한

→

Vercel · FastAPI (서울 리전)
① 개인정보 비식별화 · 인젝션 규칙 차단
② 협찬 표기 규칙 · 신뢰도 점수 · 도장 배지
③ 장소·후기 조회, 관련 글 선별, 캐시
④ 원격 GPU 기동 상태 확인 (콜드 스타트 안내)

→

한국관광공사 TourAPI 4.0
장소·축제·운영시간, 공식 번역(국·영·일·중)

NAVER API HUB 블로그 검색
후기 원문 후보 (검색 API 요약만 사용)

Modal GPU(L4) · Qwen2.5-7B-Instruct
vLLM · 보안 분류 · 숨은 광고 판단 · 번역 · 요약

Modal CPU · Fast-DetectGPT
Qwen2.5-1.5B 기반 AI 작성 확률

구성	기술	비고
화면	HTML · CSS · JavaScript (프레임워크 없음)	4 개 언어, 반응형, NDJSON 실시간 스트리밍
서버	Python · FastAPI · Pydantic · requests	Vercel Hobby(무료), 함수 최대 300 초
AI 모델	Qwen2.5-7B-Instruct(vLLM), Fast-DetectGPT	Modal 무료 크레딧 월 $30, 사용 시에만 과금
테스트 · 관리	pytest 58 개, GitHub 비공개 저장소	API 키는 저장소에 두지 않음

주요 소스 `app.py` API 서버 · `catalog.py` 장소·후기 서비스 계층 · `ai_pipeline/trust_filter.py` 판정 핵심 · `security/` 개인정보·인젝션 · `data_sources/` TourAPI·네이버 · `static/` 화면 · `deploy/` Modal 배포

4. 핵심 로직 — 신뢰도 판정 7 단계

① **수집**: TourAPI 좌표·반경 조회(`locationBasedList2`, 반경 1.5km)로 장소를 모으고, 네이버 블로그 검색(최신순+관련도순)에서 장소명이 들어간 글만 고름. 본문에만 스치듯 나온 글은 지역명도 있어야 인정

② **개인정보 가리기**: 전화·이메일·주민번호·카드·계좌·메신저 ID 를 정규식으로 가리고 건수 표시 (`security/pii.py`)
③ **숨은 명령 1 차 차단**: '이전 지시 무시' 같은 한·영 인젝션 규칙에 걸리면 AI 에 보내지 않고 '차단' (`security/injection.py`)
④ **협찬 고지 확인**: 공정위 표기(협찬·제공받아·체험단 등)가 있으면 '협찬 고지', 정상적인 홍보라 숨기지 않음 (`sponsor_rules.py`)
⑤ **문맥 읽기 (Qwen2.5-7B)**: 보안 2 차 분류(정상·의심·차단), 표기 없는 홍보 등급(none·possible·likely = 숨은 광고, explicit = 협찬을 밝힘), AI 문체 등급, 번역·요약을 JSON 스키마로만 받음. 7B 모델이 숫자 점수를 일관되게 못 매겨 등급으로 받고 코드에서 점수화
⑥ **AI 작성 판별**: Fast-DetectGPT(Qwen2.5-1.5B) 확률과 Qwen 문체 신호를 평균. 한 모델로 확정하지 않으며 60 자 미만은 판별하지 않음
⑦ **판정 도장**: 아래 식으로 점수를 내고 배지를 붙임. AI 분석이 실패하면 근거가 부족하므로 최대 '참고'(0.6)로 제한

신뢰도 = 1.0 − 협찬(협찬 고지 0.3 / 표기 없는 홍보 0.5 × 등급 0~0.7) − 0.5 × AI 작성 확률 − 0.2(보안 '의심')

배지	조건	화면 표시
신뢰	점수 0.70 이상	기본 노출
참고	0.40 이상 0.70 미만, 또는 AI 분석 실패	기본 노출
협찬 고지	협찬을 밝힌 글 (공정위 표기 또는 문맥 explicit)	기본 노출, 협찬 사실 표시
숨은 광고·AI 의심	표기 없는 홍보(문맥 likely), 또는 0.40 미만	기본 숨김, 펼치면 근거 공개
차단	프롬프트 인젝션 탐지	분석하지 않고 사유만 표시

5. 보안 설계

- **인젝션 3 중 방어**: ① 규칙 탐지로 차단 ② Qwen 보안 분류 ③ 외부 글은 시스템 프롬프트가 아닌 `<review>` 데이터 태그로만 전달하고 태그 탈출 문자열·특수 토큰 제거. 모델 출력은 JSON 스키마 + Pydantic 검증, 모델에 도구·권한 없음
- **키·접근 관리**: API 키는 `.env`, Vercel 환경변수(민감 값), Modal Secret 에만 보관하고 저장소에 커밋하지 않음. Modal GPU·판별기는 API 키 인증(키 없이 호출하면 401)
- **수집 최소화**: 네이버 블로그 robots.txt 가 AI·RAG 목적 봇을 금지하므로 본문을 크롤링하지 않고 공식 검색 API 요약만 사용. 사용자 계정·개인정보는 수집하지 않으며, 블로그 글은 `textContent` 로만 출력해 스크립트 실행(XSS) 차단

6. 실행 방법

- **웹(설치 불필요)**: https://localpass-kappa.vercel.app 접속 → 지역 선택 → 장소 카드 → '후기 검사'. GPU 가 꺼져 있으면 첫 분석 전 2~4 분간 켜지며 하단에 경과 시간이 표시됨
- **로컬**: `pip install -r requirements.txt` → `.env.example` 을 `.env` 로 복사해 키 입력(없으면 샘플 데이터로 동작) → `python app.py` → http://127.0.0.1:8000. 언어 모델은 Ollama(`qwen2.5:7b-instruct`) 또는 `deploy/modal_qwen.py` 로 Modal 에 배포. 테스트 `python -m pytest -q`

7. 검증 결과와 한계

- **AI 작성 판별기**: KatFish 한국어 벤치마크(ACL 2025)로 보정하고, 보정에 쓰지 않은 200 건으로 평가. 1,000 자 AUROC 0.76(에세이 0.92), 블로그 요약 길이인 200 자에서는 0.66
- **실제 데이터 시연**: 성수 '누메로뜨레쓰' 후기 6 건 → 신뢰 3 · 참고 1 · 의심 2 (표기 없는 해시태그 홍보, 할인·예약 유도). 직접 검사: 협찬 글 '협찬 고지'(57 점), 진짜 후기 '신뢰'(89 점), 인젝션 '차단'과 개인정보 1 건 가림. 단위 테스트 58 개 통과, Modal 판별기와 로컬 계산 점수 일치
- **한계**: AI 작성 판별은 증거가 아닌 참고 지표이며 짧은 글에서 정확도가 떨어짐. 판별기 보정 데이터(에세이·논문 초록)는 블로그 후기와 분야가 다름. 7B 모델은 고유명사 번역을 틀릴 수 있어 한글 원래 이름을 함께 표시하고 공식 번역을 우선함. 숨은 광고는 완벽히 잡지 못하므로 근거를 공개하고, 숨기되 지우지 않음

8. 기대 효과와 향후 계획

- 외국인 관광객도 한국인처럼 로컬 후기를 신뢰도와 함께 보고 고를 수 있고, 지방·골목 상권과 협찬을 밝힌 소상공인도 공정하게 노출됨
- 지역은 좌표만 추가하면 전국으로 확장(추가 크롤링 없음). 향후 블로그 후기 라벨 데이터로 판별기를 다시 보정하고, 후기 출처를 넓혀 판정 정확도를 높일 계획