LocalPass 외국인 관광객을 위한 로컬 후기 신뢰도 필터링 서비스

팀	류황규 · 박건우 · 홍승우 · 황지룡	**지원 분야**	AI·DX 산출물
서비스 주소	https://localpass-kappa.vercel.app	**제출물**	코드 설명서, 코드 결과(PPT 20 장), 소스 코드

1. 개발 배경과 목적

- 외국인이 주로 쓰는 구글맵은 한국 데이터가 부실하고, 가장 믿을 만한 **네이버 블로그 후기는 한국어로만 유통**됩니다. 번역해도 **협찬·광고 글과 AI 가 쓴 글은 가려낼 수 없고**, 광고 수익 구조상 콘텐츠가 유명 장소에 쏠려 **지방은 정보 사각지대**로 남습니다.
- LocalPass 는 공공 관광데이터(TourAPI)와 블로그 후기를 결합하고 **협찬 여부와 AI 작성 여부를 이중으로 걸러** 진짜 사람이 쓴 후기만 영어·일본어·중국어·한국어로 보여줍니다. 조사한 경쟁 서비스 6 곳(크리에이트립, 망고플레이트, 와그, 트래지, 캐치테이블, 네이버지도)에는 이런 검증 기능이 없습니다.

2. 주요 기능

구분	내용
장소 탐색	지역 6 곳(성수·전주·부산·강릉·경주·제주)과 전국 키워드 검색, 카테고리 탭(관광지·문화시설·축제·전통시장·맛집), 관심사 9 종 필터, 신뢰도순·거리순·이름순 정렬
장소 상세	TourAPI 공식 정보(주소·이용시간·쉬는 날·요금·소개)를 관광공사 공식 외국어 번역으로 우선 표시하고, 없으면 Qwen 번역에 '기계 번역' 표시
후기 신뢰도 분석	장소별 네이버 블로그 후기 6 건을 7 단계로 검사해 도장 배지(신뢰·참고·의심·차단), 신뢰도 점수, 판단 근거, 번역 요약을 끝나는 대로 한 건씩 표시 (진행 건수·경과 시간 표시)
의심 후기 처리	의심·차단 후기는 기본으로 숨기되 지우지 않고, 펼치면 판단 근거를 공개. 한국어 원문과 블로그 원본 링크 제공
직접 후기 검사	후기를 붙여 넣으면 같은 7 단계로 검사 (샘플: 진짜 후기 · 협찬 글 · 프롬프트 인젝션)
다국어 · 모바일	화면 문구·후기 요약·장소명 4 개 언어, 한글 원래 이름 병기, 스마트폰(390px) 대응, 키보드 초점·'움직임 줄이기' 설정 지원
GPU 온디맨드	AI 서버는 사이트를 쓸 때만 켜지고 5 분간 쓰지 않으면 꺼짐. 켜지는 동안(2~4 분) 화면 하단에 경과 시간 안내

3. 시스템 구성과 기술 스택

외국인 관광객
브라우저 · 모바일
영·일·중·한

→

Vercel · FastAPI (서울 리전)
① 개인정보 비식별화 · 인젝션 규칙 차단
② 협찬 표기 규칙 · 신뢰도 점수 · 도장 배지
③ 장소·후기 조회, 관련 글 선별, 캐시
④ 원격 GPU 기동 상태 확인 (콜드 스타트 안내)

→

한국관광공사 TourAPI 4.0
장소·축제·운영시간, 공식 번역(국·영·일·중)

NAVER API HUB 블로그 검색
후기 원문 후보 (검색 API 요약만 사용)

Modal GPU(L4) · Qwen2.5-7B-Instruct
vLLM · 보안 분류 · 협찬 문맥 · 번역 · 요약

Modal CPU · Fast-DetectGPT
Qwen2.5-1.5B 기반 AI 작성 확률

구성	기술	비고
화면	HTML · CSS · JavaScript (프레임워크 없음)	4 개 언어, 반응형, NDJSON 실시간 스트리밍
서버	Python · FastAPI · Pydantic · requests	Vercel Hobby(무료), 함수 최대 300 초
AI 모델	Qwen2.5-7B-Instruct(vLLM), Fast-DetectGPT	Modal 무료 크레딧 월 $30, 사용 시에만 과금
테스트 · 관리	pytest 35 개, GitHub 비공개 저장소	API 키는 저장소에 두지 않음

주요 소스 `app.py` API 서버 · `catalog.py` 장소·후기 서비스 계층 · `ai_pipeline/trust_filter.py` 판정 핵심 · `security/` 개인정보·인젝션 · `data_sources/` TourAPI·네이버 · `static/` 화면 · `deploy/` Modal 배포

4. 핵심 로직 — 신뢰도 판정 7 단계

① **수집**: TourAPI 좌표·반경 조회(`locationBasedList2`, 반경 1.5km)로 장소를 모으고, 네이버 블로그 검색(최신순+관련도순)에서 장소명이 들어간 글만 고름. 본문에만 스치듯 나온 글은 지역명도 있어야 인정

② **개인정보 가리기**: 전화·이메일·주민번호·카드·계좌·메신저 ID 를 정규식으로 가리고 건수 표시 (`security/pii.py`)
③ **숨은 명령 1 차 차단**: '이전 지시 무시' 같은 한·영 인젝션 규칙에 걸리면 AI 에 보내지 않고 '차단' (`security/injection.py`)
④ **협찬 표기 찾기**: 공정위 지침 표기(협찬·제공받아·원고료·체험단·#광고 등)가 있으면 협찬 확정 (`sponsor_rules.py`)
⑤ **문맥 읽기 (Qwen2.5-7B)**: 보안 2 차 분류(정상·의심·차단), 표기 없는 홍보의 협찬 등급(none·possible·likely·explicit), AI 문체 등급, 번역·요약을 JSON 스키마로만 받음. 7B 모델이 숫자 점수를 일관되게 못 매겨 등급으로 받고 코드에서 점수화
⑥ **AI 작성 판별**: Fast-DetectGPT(Qwen2.5-1.5B) 확률과 Qwen 문체 신호를 평균. 한 모델로 확정하지 않으며 60 자 미만은 판별하지 않음
⑦ **판정 도장**: 아래 식으로 점수를 내고 배지를 붙임. AI 분석이 실패하면 근거가 부족하므로 최대 '참고'(0.6)로 제한

> **신뢰도 = 1.0 − 협찬(표기 발견 0.5 / 없으면 0.5 × 문맥 등급 0~0.95) − 0.5 × AI 작성 확률 − 0.2(보안 '의심')**

배지	조건	화면 표시
신뢰	점수 0.70 이상	기본 노출
참고	0.40 이상 0.70 미만, 또는 AI 분석 실패	기본 노출
협찬·AI 의심	협찬 판정(표기 발견 또는 문맥 likely 이상), 또는 0.40 미만	기본 숨김, 펼치면 근거 공개
차단	프롬프트 인젝션 탐지	분석하지 않고 사유만 표시

5. 보안 설계

- **인젝션 3 중 방어**: ① 규칙 탐지로 차단 ② Qwen 보안 분류 ③ 외부 글은 시스템 프롬프트가 아닌 `<review>` 데이터 태그로만 전달하고 태그 탈출 문자열·특수 토큰 제거. 모델 출력은 JSON 스키마 + Pydantic 검증, 모델에 도구·권한 없음
- **키·접근 관리**: API 키는 `.env`, Vercel 환경변수(민감 값), Modal Secret 에만 보관하고 저장소에 커밋하지 않음. Modal GPU·판별기는 API 키 인증(키 없이 호출하면 401)
- **수집 최소화**: 네이버 블로그 robots.txt 가 AI·RAG 목적 봇을 금지하므로 본문을 크롤링하지 않고 공식 검색 API 요약만 사용. 사용자 계정·개인정보는 수집하지 않으며, 블로그 글은 `textContent` 로만 출력해 스크립트 실행(XSS) 차단

6. 실행 방법

- **웹(설치 불필요)**: https://localpass-kappa.vercel.app 접속 → 지역 선택 → 장소 카드 → '후기 검사'. GPU 가 꺼져 있으면 첫 분석 전 2~4 분간 켜지며 하단에 경과 시간이 표시됨
- **로컬**: `pip install -r requirements.txt` → `.env.example` 을 `.env` 로 복사해 키 입력(없으면 샘플 데이터로 동작) → `python app.py` → http://127.0.0.1:8000. 언어 모델은 Ollama(`qwen2.5:7b-instruct`) 또는 `deploy/modal_qwen.py` 로 Modal 에 배포. 테스트 `python -m pytest -q`

7. 검증 결과와 한계

- **AI 작성 판별기**: KatFish 한국어 벤치마크(ACL 2025)로 보정하고, 보정에 쓰지 않은 200 건으로 평가. 1,000 자 AUROC 0.76(에세이 0.92), 블로그 요약 길이인 200 자에서는 0.66
- **실제 데이터 시연**: 성수 '누메로뜨레쓰' 후기 6 건 → 신뢰 3 · 참고 1 · 의심 2 (해시태그 홍보, 할인·예약 유도 탐지). 직접 검사: 협찬 글 '의심'(37 점), 진짜 후기 '신뢰'(89 점), 인젝션 '차단'과 개인정보 1 건 가림. 단위 테스트 35 개 통과, Modal 판별기와 로컬 계산 점수 일치
- **한계**: AI 작성 판별은 증거가 아닌 참고 지표이며 짧은 글에서 정확도가 떨어짐. 판별기 보정 데이터(에세이·논문 초록)는 블로그 후기와 분야가 다름. 7B 모델은 고유명사 번역을 틀릴 수 있어 한글 원래 이름을 함께 표시하고 공식 번역을 우선함. 표기 없는 협찬은 완벽히 잡지 못하므로 근거를 공개하고, 숨기되 지우지 않음

8. 기대 효과와 향후 계획

- 외국인 관광객도 한국인처럼 로컬 후기를 신뢰도와 함께 보고 고를 수 있고, 광고 예산 없는 지방·골목 상권도 노출됨
- 지역은 좌표만 추가하면 전국으로 확장(추가 크롤링 없음). 향후 블로그 후기 라벨 데이터로 판별기를 다시 보정하고, 후기 출처를 넓혀 판정 정확도를 높일 계획