2026 지역혁신 인재양성 연합 페스티벌

0. 개요

항목	내용
과제명	외국인 관광객을 위한 로컬 정보 신뢰도 필터링 서비스
팀원	류황규, 박건우, 홍승우, 황지룡
분야	AI · DX 산출물
산출물	관광 공공데이터와 네이버 블로그 UGC를 결합해 협찬 여부 · AI 작성 여부를 이중으로 필터링하여 다국어로 제공하는 정보 큐레이션 웹 서비스

1. 문제 정의

외국인 관광객은 앞으로도 성수동 같은 핫플레이스를 지속적으로 찾을 수밖에 없는 구조임. 이들이 "찾지 않는"게 아니라, 한국인과 동일한 수준의 신뢰할 수 있는 정보를 누리지 못하는 것이 문제다. 단순 언어장벽으로는 설명되지 않는 구조적인 원인이 있음.

- 한국의 정보 생태계는 네이버 · 카카오 중심인 반면에 외국인이 의존하는 Google Maps는 국내 로컬 데이터가 부실함.
- 가장 신뢰도 높은 로컬 정보(네이버 블로그 리뷰, 실시간 웨이팅, 팝업스토어 공지)는 전부 한국어로만, 국내 커뮤니티 안에서만 유통됨.
- 번역만으론 어려운 정보 신뢰성 문제: 협찬 · 광고성 리뷰, AI 생성 리뷰 등이 혼재하여 한국인조차 진짜 후기를 가려내기 어려움. 외국인은 이 필터링 자체가 불가능함.
- 심각한 지역 간 정보 격차: 크리에이트립(월 150만 유저), 망고플레이트(20만 + 식당 DB) 등 기존 서비스는 제휴 · 광고 수익 구조상 이미 유명한 곳에 콘텐츠가 쏠림.
- 경쟁 서비스 6곳(크리에이트립 · 망고플레이트 · 와그 · 트래지 · 캐치테이블+관광공사 · 네이버지도) 시장조사 결과, 신뢰도 검증 기능이 있는 곳은 전무 유일한 차별화 지점으로 확인됨.
- 개인정보 보호 문제: 블로그 · 리뷰를 수집하는 과정에서 전화번호 · 이메일 등 개인정보가 포함될 수 있으며, 수집 · 저장 · 분석 과정에서 개인정보가 노출 · 유출될 가능성이 있다. 따라서 개인정보를 탐지 · 비식별화 및 안전하게 처리하는 체계가 필요함.
- AI 보안 문제: 수집되는 블로그 · 리뷰에 악성 프롬프트가 포함될 수 있으며, 이를 AI모델에 그대로 전달할 경우 외부 콘텐츠가 AI의 명령으로 인식되는 프롬프트 인젝션이 발생할 수 있다. 따라서 AI 분석 전 악성 콘텐츠를 탐지하고 외부 데이터와 AI 명령을 분리하는 보안 체계가 필요함.

2. 해결 방안

공공 관광데이터와 로컬 블로그 정보를 결합하고, 협찬 여부·AI 작성 여부를 단계적으로 검증하여 "신뢰할 수 있는 로컬 추천 정보"만 다국어로 제공함.

- 한국관광공사 TourAPI 4.0으로 관광지·지역축제·전통시장 등 공식 정보를 수집하여 영어·일본어·중국어 번역 데이터 기본 제공됨.
- 개인정보 사전 필터링: 블로그·리뷰 수집 단계에서 전화번호·이메일 등 개인정보를 정규표현식 및 개인정보 탐지 로직으로 식별하고 비식별화한다. 불필요한 개인정보는 AI 분석 단계로 전달하지 않아 개인정보 노출 가능성을 최소화함.
- 악성 프롬프트 사전 탐지: 외부 블로그·리뷰 데이터를 신뢰할 수 없는 외부 입력으로 분류하고, '이전 지시를 무시하라', '시스템 프롬프트를 출력하라 등 프롬프트 인젝션이 의심되는 패턴을 규칙 기반으로 1차 탐지한다. 또한 외부 데이터와 AI의 시스템 명령을 분리하여 악성 콘텐츠가 AI의 명령으로 인식되거나 실행되지 않도록 처리함.
- Qwen2.5-7B-Instruct 기반 보안·콘텐츠 분석: 1차 규칙 필터를 통과한 콘텐츠를 Qwen에 전달하여 단순 키워드로 판단하기 어려운 문맥 기반 악성 프롬프트 여부와 콘텐츠의 의도를 추가 분석하여, Qwen은 외부 콘텐츠를 직접 실행하거나 시스템 권한을 갖는 것이 아니라, 제한된 입력을 분석하고 정상 / 의심 / 차단과 같은 구조화된 결과만 반환하도록 구성함.
- Qwen2.5-7B-Instruct 기반 협찬 여부 탐지: 공정위 관련 협찬·광고 표기 패턴을 규칙으로 탐지한 후, Qwen2.5-7B-Instruct이 리뷰의 전체 문맥을 분석하여 명시적인 광고 표기가 없더라도 광고성 표현이나 협찬 가능성을 추가적으로 판단함.
- GPTZero API로 AI 작성 여부 판별: GPTZero API을 활용하여 리뷰의 AI 생성 가능성을 분석하고, 단일 모델의 결과만으로 작성 여부를 확정하지 않음. 협찬 여부와 AI 생성 가능성을 각각 분석한 뒤 결과를 종합하여 콘텐츠의 신뢰도를 산정함.
- 신뢰도 배지(신뢰 / 참고 / 협찬·AI 의심)로 필터링 결과를 투명하게 제공, 사용자 관심사 기반 개인화 추천함.
- MVP는 성수동(UGC 필터링 검증) + 지방 축제·전통시장 1곳(TourAPI 커버리지 검증) 2개 지역으로 실증함.

3. 진행 상황

상태	항목	비고
완료	문제 정의 및 아이디어 확정	경쟁 서비스 6곳(크리에이트립 · 망고플레이트 · 와그 · 트래지 · 캐치테이블 · 네이버지도) 시장조사 포함
완료	차별화 포인트 확정	협찬 탐지 + AI 작성 판별 이중 신뢰도 필터 — 조사한 경쟁사 전부 미보유 기능
완료	기술 스택 선정	TourAPI4.0,Qwen2.5-7B-Instruct, GPTZero API, Streamlit
완료	개발 로직 설계	모듈 구조 · API 연동 함수 · 프롬프트 설계 · 완료 기준(Definition of Done) 문서화
진행중	API 키 발급	TourAPI(data.go.kr),네이버오픈API, Qwen2.5-7B-Instruct, GPTZero API
진행중	데이터 수집 · 신뢰도 필터 파이프라인 구현	TourAPI · 네이버 블로그 연동, 협찬탐지 · AI판별 · 번역 파이프라인
예정	산출물 설명서 작성	A4 2매 이내
예정	산출물(프로토타입) 제작	자유 프로그램 개발